

SVD & YOLO per la Steganografia di Immagini

Progetto d'esame — Statistical and Mathematical Methods for AI

Valutazione su **128 immagini** del dataset COCO-128. Rilevatore YOLO: attivo. Tutti i numeri di questo report sono generati automaticamente dai risultati sperimentali (results/summary.json).

1. Descrizione del problema

La **steganografia di immagini** consiste nel nascondere un'informazione segreta dentro un'immagine cover in modo che la presenza stessa del messaggio sia impercettibile. A differenza della crittografia (che rende il messaggio illeggibile ma evidente), la steganografia mira all'**invisibilità**.


Obiettivo del progetto: realizzare uno schema di steganografia che (i) sfrutti la **Decomposizione ai Valori Singolari (SVD)** — argomento centrale del corso — come strumento sia di compressione del segreto sia di dominio di embedding; e (ii) usi un rilevatore di oggetti **YOLO** per rendere l'occultamento content-adaptive, nascondendo i dati nello sfondo e preservando le regioni semanticamente importanti.

Tre requisiti guidano la valutazione, in tensione tra loro: **impercettibilità** (il cover non deve cambiare visibilmente), **capacità** (quanti bit possiamo nascondere) e **robustezza** (il segreto deve sopravvivere a manipolazioni come la ricompressione JPEG).


2. Metodo e background teorico

2.1 SVD e teorema di Eckart-Young

Per ogni matrice $A \in \mathbb{R}^{(m \times n)}$ vale $A = U \Sigma V^T$ con U, V ortogonali e $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r)$, $\sigma_1 \geq \dots \geq \sigma_r > 0$. La SVD troncata $A_k = \sum_{i=1}^k \sigma_i u_i v_i^T$ è, per il teorema di Eckart-Young, la migliore approssimazione di rango k sia in norma spettrale ($\|A - A_k\|_2 = \sigma_{k+1}$) sia di Frobenius ($\|A - A_k\|_F = (\sum_{i>k} \sigma_i^2)^{1/2}$).




Spettro dei valori singolari di un cover ed energia cumulata: poche componenti catturano la quasi totalità dell'energia.



Verifica numerica del teorema di Eckart-Young (teoria vs misura) e fattore di compressione $k(m+n+1)/mn$.

2.2 Compressione del segreto (riduzione di dimensionalità)

Il segreto S viene sostituito dalla sua approssimazione di rango k e memorizzato nei fattori compatti (U_k, σ_k, V_k^T). Il payload passa da $m \cdot n$ a $k(m+n+1)$ numeri: è la stessa compressione con perdita vista a lezione (slide 'Reduction of memory occupation'). I fattori sono quantizzati (U, V a int8, σ a float16) per ridurre ulteriormente il payload.



Ricostruzione del segreto al variare del rango k : aumentando k migliora la fedeltà (NC) ma cresce il payload.

2.3 Ruolo dei valori singolari nell'embedding

La scelta di codificare l'informazione nei valori singolari — e in particolare in σ_1 — discende da quattro proprietà. (i) **Concentrazione di energia**: per i blocchi $B \times B$ di immagini naturali σ_1^2 raccoglie il 95–99 % dell'energia $\|A\|_F^2 = \sum \sigma_i^2$ (Eckart-Young): σ_1 è la coordinata più significativa del blocco nella base di matrici di rango 1 $\{u_i v_i^T\}$. (ii) **Stabilità**: per il teorema di Weyl (§2.5) una perturbazione E sposta tutti i σ_i al più di $\|E\|_2$ in assoluto, quindi la perturbazione relativa è minima su σ_1 e massima sui σ_i piccoli — in linea con l'osservazione del corso per cui i piccoli valori singolari amplificano il rumore. Un bit scritto in un σ_i piccolo sarebbe illeggibile già dopo un attacco lieve. (iii) **Invarianza geometrica**: i σ_i non cambiano per trasformazioni ortogonali del blocco, sono un descrittore intrinseco dell'energia. (iv) **Distorsione distribuita**: variare σ_1 di δ cambia il blocco di $\delta \cdot u_1 v_1^T$ con $\|\delta \cdot u_1 v_1^T\|_F = |\delta|$, spalmato su tutti i B^2 pixel lungo la componente più liscia del blocco; modificare un σ_i piccolo inietterebbe invece componenti oscillanti simili a rumore, più visibili e più facili da rilevare.

2.4 Embedding e decodifica (QIM su σ_1)

Embedding. Il segreto compresso è serializzato in un bitstream auto-descrittivo: header di 9 byte (magic, versione, h, w, k), poi i k valori singolari in float16 e i fattori U_k, V_k^T quantizzati a int8 (le loro colonne/righe hanno norma unitaria, quindi elementi in $[-1, 1]$ e scala fissa 127). La lunghezza totale, $9 + 2k + k(h+w)$ byte, dipende solo da (h, w, k) . Il cover è diviso in blocchi $B \times B$; l'ordine dei blocchi è fissato da una chiave PRNG e dalla

mappa di priorità YOLO (sfondo prima). Per ogni blocco portante $A = U\Sigma V^T$ il bit b è codificato per Quantisation Index Modulation: $\sigma_1' = \lfloor \sigma_1/\Delta \rfloor \cdot \Delta + 0.25\Delta$ ($b=0$) oppure $+ 0.75\Delta$ ($b=1$), e il blocco è ricostruito come $A' = U\Sigma'V^T$ (i vettori singolari restano invariati). I due offset sono i centri delle due semicelle dell'intervallo di quantizzazione: la scelta rende simmetrico e massimo il margine di errore, pari a $\Delta/4$. Con ridondanza $R>1$ ogni bit logico è scritto in R siti consecutivi (codice a ripetizione).

Decodifica (cieca). L'estrazione non richiede né il cover originale né i σ originali (a differenza dello schema di Liu-Tan, che conserva U, V ed è per questo vulnerabile a false estrazioni): servono solo chiave, parametri (B, Δ, R) e la mappa di priorità. Si ricostruisce lo stesso ordinamento dei blocchi; per ciascun blocco si calcola la SVD e si decide dalla parte frazionaria di σ_1/Δ : $b=0$ se $(\sigma_1/\Delta \bmod 1) < 0.5$, $b=1$ altrimenti — la cella di decisione è larga $\Delta/2$ e il valore embedded siede al suo centro. Con $R>1$ il bit logico è il voto di maggioranza degli R siti. Si leggono prima i 72 bit dell'header, se ne valida la plausibilità e da (h, w, k) si determina la lunghezza esatta del payload; quindi si de-serializzano $\tilde{\sigma}$ (float16) e $\tilde{U}_k, \tilde{V}_k^T$ (int8/127) e si ricostruisce $\hat{S} = \tilde{U}_k \cdot \text{diag}(\tilde{\sigma}) \cdot \tilde{V}_k^T$ con clip in $[0, 255]$. Il parser è difensivo: σ corrotti (NaN/inf) vengono azzerati, così la componente danneggiata viene eliminata e la ricostruzione degrada al rango inferiore invece di esplodere.

2.5 Effetto delle perturbazioni: teorema di Weyl

Un attacco trasforma il blocco stego A' in $A' + E$. Il teorema di Weyl limita lo spostamento di ogni valore singolare: $|\sigma_i(A' + E) - \sigma_i(A')| \leq \|E\|_2 \leq \|E\|_F$. Ne segue la **condizione di decodifica corretta**: il bit QIM resta corretto se $\|E\|_2 < \Delta/4$. Per rumore gaussiano i.i.d. con deviazione σ_n la teoria delle matrici casuali dà $\|E\|_2 \approx 2\sigma_n\sqrt{B}$; con $\sigma_n = 5$ (attacco gauss_noise5) si prevede: HC ($B=8$, margine $\Delta/4 = 6$ contro $\|E\|_2 \approx 28$) → molti bit ribaltati; RB ($B=16$, margine 32 contro ≈ 40) → errori sporadici corretti dal voto di maggioranza. È esattamente ciò che la tabella di robustezza (§5.5) misura: i risultati sperimentali sono previsti dalla teoria delle perturbazioni, non solo osservati. Sulla **ricostruzione**, l'errore totale $\|S - \hat{S}\|_F$ si decompone in tre contributi: troncamento (Eckart-Young: $(\sum_{i>k} \sigma_i^2)^{1/2}$, il tetto di fedeltà in pulito), quantizzazione dei fattori (trascurabile) ed errori di bit, il cui effetto è fortemente non uniforme: un bit errato su U/V altera un solo elemento int8 (degrado graduale), un bit sugli esponenti di un σ float16 può amplificare la componente per ordini di grandezza (mitigato dall'azzeramento dei σ implausibili), un bit sull'header è fatale — per questo l'header occupa i primi siti dell'ordinamento ed è protetto dalla ripetizione. Questa gerarchia spiega perché la NC crolla in modo non lineare al crescere del BER e perché la modalità robusta richiede il codice a ripetizione.

2.6 Guida YOLO (content-adaptive)

YOLOv8 rileva gli oggetti nel cover; dalle bounding box si costruisce una mappa di saliency. L'ordine di riempimento dei blocchi privilegia lo **sfondo** (saliency bassa), lasciando quasi intatte le regioni degli oggetti. YOLO viene poi usato anche per **valutare** quanto le detection si conservano sul cover rispetto allo stego (preservation rate, IoU, mAP@0.5).

3. Implementazione

Il progetto è in Python (NumPy, OpenCV, scikit-image, Ultralytics YOLOv8, Matplotlib). Moduli principali: svd_core (matematica SVD), steganography (codec del segreto + embedding/estrazione), yolo_guidance (rilevamento e metriche), metrics, attacks, dataset, pipeline.

Sono definiti due **punti operativi** che illustrano il compromesso capacità↔robustezza:

Parametro	High-Capacity (HC)	Robust (RB)
Blocco SVD	8×8	16×16
Passo QIM Δ	24.0	128.0
Ripetizione R	1	3
Segreto	64×64, k=10	16×16, k=3
Capacità (bpp)	0.0469	0.0039

3.1 Motivazione teorica della scelta dei parametri

Passo Δ . Assumendo la fase $\sigma_1 \bmod \Delta$ uniforme (vero per $\sigma_1 \gg \Delta$) e bit equiprobabili, lo spostamento δ di σ_1 in embedding ha $E[\delta^2] = 7\Delta^2/48$; la modifica di norma $|\delta|$ si spalma su B^2 pixel e solo una frazione α dei blocchi porta bit, quindi il PSNR atteso è $10 \cdot \log_{10}(255^2 \cdot B^2 / (\alpha \cdot 7\Delta^2/48))$. La predizione coincide con la misura: HC $\alpha = 0.85 \rightarrow$ PSNR atteso 47.6 dB contro 47.4 dB misurati; RB $\alpha = 0.87 \rightarrow$ atteso 39.0 dB contro 39.0 dB (scarto < 0.3 dB, dovuto ad arrotondamento e clipping a uint8): la distorsione è interamente governata dalla teoria. Sul lato robustezza, la condizione di Weyl $\Delta/4 > \|E\|_2 \approx 2\sigma_n \sqrt{B}$ dà la regola di progetto $\Delta > 8\sigma_n \sqrt{B}$: RB ($\Delta=128.0$, margine 32) tollera per costruzione rumore con $\sigma_n \approx 4$, HC ($\Delta=24.0$, margine 6) solo $\sigma_n \approx 0.75$ — la fragilità di HC è il prezzo, scelto, del massimo PSNR e capacità.

Blocco B. I siti portanti sono $3(N/B)^2$: dimezzare B quadruplica la capacità (12288 siti con $B=8$ contro 3072 con $B=16$). Per la robustezza vale l'argomento opposto: per un blocco quasi costante di livello c si ha $\sigma_1 \approx cB$, che cresce linearmente in B, mentre la perturbazione attesa $2\sigma_n \sqrt{B}$ cresce solo come $\sqrt{B}$ — i blocchi grandi tollerano passi Δ più ampi in rapporto a σ_1 , e la loro componente $u_1 v_1^T$ è a frequenza più bassa, quindi sopravvive meglio a blur e JPEG.

Rango k del segreto. Due vincoli: il criterio dell'energia del corso (il più piccolo k con $E(k)$ sopra soglia — per il segreto 64×64, $E(8) = 98.7\%$, $E(10) = 99.1\%$: k=10 è il più piccolo rango con energia $\geq 99\%$) e il vincolo di capacità $8 \cdot [9 + 2k + k(h+w)] \cdot R \leq 3(N/B)^2$. In HC k=10 richiede 10472 bit su 12288 (utilizzo 85%), mentre k=12 non entrerebbe (12552 bit); in RB k=3 richiede $888 \times 3 = 2664$ bit su 3072, mentre k=4 non entrerebbe (3480). In HC k è scelto dall'energia, in RB è il massimo rango compatibile con la ridondanza.

Ripetizione R. R è dispari perché il voto di maggioranza non ammetta pareggi. Se p è la probabilità di errore del singolo sito, con $R=3$ l'errore sul bit logico è $3p^2(1-p) + p^3 \approx 3p^2$: un canale con $p = 5\%$ scende allo 0.7%. È il salto qualitativo tra le colonne HC e RB della tabella di robustezza, pagato con 1/3 della capacità; $R=3$ è il minimo dispari > 1 , e valori maggiori renderebbero il payload RB incompatibile con la capacità.


4. Setup sperimentale

- Dataset: COCO-128 (128 immagini reali di COCO), cover ridimensionati a 512×512.
- Segreto: logo grayscale sintetico (forme + gradiente), compresso via SVD troncata.
- Metriche di fedeltà: PSNR, SSIM, MSE (cover vs stego), globali e per regione (oggetto vs sfondo).
- Metriche di payload: NC (correlazione normalizzata) e PSNR del segreto recuperato, BER.
- Downstream: preservation rate, IoU medio, mAP@0.5, $|\Delta\text{confidenza}|$ (cover vs stego).
- Attacchi: JPEG (q90/q75/q50), rumore gaussiano, blur, mediano, sale&pepe, rescale.

5. Risultati

5.1 Impercettibilità


In modalità HC il cover e lo stego sono praticamente indistinguibili: PSNR medio **47.39 dB**, SSIM **0.9950**. In modalità RB (più robusta) PSNR medio **39.04 dB**, SSIM **0.9820**.



Distribuzione di PSNR e SSIM cover→stego sulle immagini di test.


5.2 Protezione degli oggetti tramite YOLO

La guida YOLO sposta il payload nello sfondo: il PSNR **nelle regioni degli oggetti** sale da 47.40 dB (baseline senza YOLO) a **50.39 dB** (guidato), un miglioramento di **2.99 dB** esattamente dove l'occhio (e il rilevatore) guardano. Lo sfondo, di contro, passa da 47.40 a 46.82 dB.



PSNR per regione (oggetto vs sfondo): la guida YOLO protegge gli oggetti.

Qualitative results — YOLO-guided embedding avoids object regions




Risultati qualitativi: la mappa |cover-stego| mostra che le modifiche evitano le regioni degli oggetti.

5.3 Preservazione del contenuto semantico (downstream)

Le detection di YOLO si conservano quasi perfettamente dopo l'embedding: preservation rate medio **0.961**, mAP@0.5 medio **0.959**, variazione media di confidenza **0.016**. Lo stego è quindi utilizzabile in una pipeline di AI a valle senza degradarne le prestazioni.


Downstream YOLO detection preserved after embedding (High-Capacity)



Distribuzione di preservation rate, mAP@0.5 e |Δconfidenza|.

5.4 Recupero del segreto e compressione SVD

Su immagine non attaccata, il segreto si recupera con NC medio **0.923** (HC) e **0.929** (RB), con BER ≈ 0.00150 (HC). Il limite di fedeltà in pulito è dato dalla **compressione SVD troncata** del segreto, non dall'estrazione: aumentando k la qualità cresce a scapito del payload.




Qualità di ricostruzione (PSNR/energia) e fattore di compressione del segreto al variare del rango k.


5.5 Robustezza agli attacchi

La modalità RB (blocchi 16×16 , Δ grande, ripetizione $\times 3$) resiste agli attacchi comuni, mentre la modalità HC — priva di ridondanza — è fragile: è il prezzo della massima capacità.

Attacco	NC (HC)	NC (RB)	BER (HC)	BER (RB)
jpeg_q90	0.000	0.908	0.215	0.001
jpeg_q75	0.000	0.859	0.396	0.002
jpeg_q50	0.000	0.471	0.478	0.009
gauss_noise5	0.000	0.863	0.368	0.003
blur_3x3	0.039	0.705	0.192	0.016
median_3x3	0.051	0.515	0.204	0.049
saltpepper_1	0.000	0.054	0.233	0.089
rescale_50	0.014	0.552	0.237	0.036



NC del segreto recuperato e BER del payload sotto attacco.



Fronte di Pareto capacità↔robustezza tra le due modalità.

6. Analisi e commenti

- Il valore singolare massimo σ_1 è un dominio di embedding eccellente: concentra l'energia del blocco (Eckart-Young) e, per il teorema di Weyl, è la componente con perturbazione relativa minima — in linea con l'osservazione del corso che i piccoli σ amplificano il rumore.
- Il PSNR misurato coincide (entro 0.3 dB) con quello previsto dalla formula teorica $10 \cdot \log_{10}(255^2 \cdot B^2 / (\alpha \cdot 7 \Delta^2 / 48))$: la distorsione dell'embedding è interamente spiegata dalla teoria (§3.1).
- La guida YOLO migliora la qualità nelle regioni salienti (+3.0 dB sugli oggetti) senza intaccare la capacità, e mantiene mAP ≈ 0.96 .
- Esiste un chiaro compromesso capacità↔robustezza governato da tre leve SVD (dimensione blocco, passo Δ , ridondanza R): non è possibile massimizzare contemporaneamente capacità, impercettibilità e robustezza.
- La compressione del segreto via SVD troncata abilita payload elevati ma, eliminando la ridondanza spaziale, rende il recupero sensibile agli errori di bit: per la robustezza è necessaria una codifica di canale (ripetizione).

7. Conclusioni

Il progetto mostra come la SVD — cuore del corso — fornisca un quadro unificato per la steganografia: compressione del segreto (Eckart-Young), dominio di embedding robusto (σ_1), e analisi del condizionamento. L'integrazione con YOLO rende l'occultamento

adattivo al contenuto e verificabile a valle. I risultati su 100+ immagini COCO quantificano impercettibilità, preservazione semantica e il compromesso capacità↔robustezza.

Riferimenti

- C. Eckart, G. Young, 'The approximation of one matrix by another of lower rank', Psychometrika, 1936.
- H. Weyl, 'Das asymptotische Verteilungsgesetz der Eigenwerte linearer partieller Differentialgleichungen', Math. Ann., 1912 (disuguaglianze di perturbazione dei valori singolari).
- B. Chen, G. Wornell, 'Quantization Index Modulation: a class of provably good methods for digital watermarking and information embedding', IEEE Trans. Inf. Theory, 2001.
- G. H. Golub, C. Van Loan, 'Matrix Computations', 4th ed., 2013.
- R. Liu, T. Tan, 'An SVD-based watermarking scheme for protecting rightful ownership', IEEE Trans. Multimedia, 2002.
- G. Jocher et al., 'Ultralytics YOLOv8', 2023.
- T.-Y. Lin et al., 'Microsoft COCO: Common Objects in Context', ECCV 2014.
- M. Popolizio, slide del corso 'Reducing data dimensionality for AI applications', 2025.