

Steganografia di Immagini basata su SVD con Guida YOLO

Compressione e occultamento di informazione mediante Decomposizione ai Valori Singolari, con embedding adattivo al contenuto

Progetto d'esame — Statistical and Mathematical Methods for AI (Prof. M. Popolizio)

Valutazione sperimentale su 128 immagini reali del dataset COCO-128 — rilevatore YOLOv8 attivo

Sommario

Questo progetto realizza e valuta uno schema di **steganografia di immagini** in cui la **Decomposizione ai Valori Singolari (SVD)** — argomento centrale del corso — compare in due ruoli distinti e complementari. In primo luogo la SVD troncata, ottimale per il teorema di Eckart-Young, comprime l'immagine segreta riducendone l'occupazione di memoria; in secondo luogo l'SVD a blocchi fornisce il dominio in cui nascondere il messaggio, modulando il valore singolare massimo di ogni blocco (Quantisation Index Modulation). Un rilevatore di oggetti **YOLOv8** rende l'occultamento **adattivo al contenuto**, spingendo l'informazione nello sfondo e proteggendo le regioni semanticamente rilevanti; lo stesso rilevatore quantifica poi quanto il contenuto sopravvive all'embedding.

Sull'intero COCO-128 (128 immagini) lo schema raggiunge un'impercettibilità elevata (PSNR medio **47.39 dB**, SSIM **0.9950** in modalità ad alta capacità), preserva quasi perfettamente le rilevazioni a valle (mAP@0.5 medio **0.959**) e recupera il segreto in assenza di attacchi con correlazione normalizzata media **0.923**. Una seconda modalità, robusta, sopravvive ad attacchi comuni (JPEG, rumore, filtri) grazie a blocchi più grandi e a un codice a ripetizione. I risultati quantificano in modo esplicito il compromesso fondamentale tra **capacità**, **impercettibilità** e **robustezza**, governato interamente da grandezze legate alla SVD.

1. Introduzione e obiettivi

La **steganografia** nasconde un'informazione dentro un mezzo apparente (qui un'immagine cover) in modo che la presenza stessa del messaggio resti impercettibile. Si differenzia dalla crittografia, che rende il messaggio illeggibile ma non ne nasconde l'esistenza: la steganografia punta all'**invisibilità**, non solo alla segretezza.

Un buon schema steganografico deve bilanciare tre requisiti in tensione tra loro:

- **Impercettibilità** — il cover modificato (stego) non deve risultare visibilmente alterato (PSNR/SSIM elevati);
- **Capacità** — quanti bit di informazione si riescono a nascondere (bit per pixel, bpp);
- **Robustezza** — il messaggio deve sopravvivere a manipolazioni involontarie o ostili (ricompressione JPEG, rumore, ridimensionamento).

L'obiettivo del progetto è costruire uno schema che (i) usi la **SVD** come strumento matematico unificante — sia per comprimere il segreto sia come dominio di embedding — e (ii) sfrutti un rilevatore di oggetti per rendere l'occultamento **content-adaptive**: nascondere i dati dove l'occhio e gli algoritmi a valle guardano meno, cioè nello sfondo, preservando gli oggetti. Oltre a misurare le metriche classiche, si verifica una proprietà nuova e utile: che l'immagine stego resti **usabile da una pipeline di intelligenza artificiale a valle**,

mantenendo inalterate le rilevazioni di YOLO.

2. Background matematico

Tutta la notazione segue le slide del corso. La SVD è lo strumento centrale: se ne richiamano le proprietà usate nel progetto.

2.1 Decomposizione ai Valori Singolari

Per ogni matrice reale A di dimensione $m \times n$ esistono due matrici ortogonali U ($m \times m$) e V ($n \times n$) e una matrice diagonale Σ tali che $A = U \Sigma V^T$, con $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ valori singolari e $r = \text{rango}(A)$. Equivalentemente A si scrive come somma di matrici di rango 1 ordinate per importanza decrescente:

$$A = \sum_i \sigma_i \cdot u_i v_i^T \quad (i = 1 \dots r)$$

I vettori singolari u_i, v_i hanno norma unitaria: questa proprietà sarà cruciale per stimare la distorsione dell'embedding (Sez. 3.3). Implementazione: `svd_core.svd_decompose`.

2.2 SVD troncata e teorema di Eckart-Young

Trattenendo i primi k termini si ottiene la SVD troncata $A_k = \sum_{i \leq k} \sigma_i u_i v_i^T$. Il teorema di Eckart-Young afferma che A_k è la **migliore approssimazione di rango k** di A , sia in norma spettrale sia di Frobenius, e che l'errore è governato esattamente dai valori singolari scartati:

$$\|A - A_k\|_2 = \sigma_{k+1} \quad \|A - A_k\|_F = \left(\sum_{i > k} \sigma_i^2 \right)^{1/2}$$

La **frazione di energia** trattenuta da A_k , $E(k) = (\sum_{i \leq k} \sigma_i^2) / (\sum_i \sigma_i^2)$, fornisce un criterio pratico per scegliere k . La Fig. 1 mostra, su un cover reale, che lo spettro dei valori singolari decade rapidamente e che **poche componenti catturano la quasi totalità dell'energia** (90% con $k=3$, 95% con $k=8$, 99% con $k=41$ su una matrice 512×512): è la ragione per cui le immagini naturali sono comprimibili. La Fig. 2 verifica numericamente Eckart-Young, mostrando che l'errore di approssimazione misurato coincide con la previsione teorica.




Fig. 1 — Spettro dei valori singolari di un cover (scala log) ed energia cumulata: il decadimento rapido giustifica la compressione a basso rango.




Fig. 2 — Verifica del teorema di Eckart-Young: errore teorico vs misurato (norma 2 e Frobenius) e fattore di compressione $k(m+n+1)/mn$ al crescere di k.

2.3 Occupazione di memoria e fattore di compressione

Memorizzare A_k richiede le k colonne di U_k , i k valori singolari e le k righe di V_k^T , cioè $k(m+n+1)$ numeri contro gli mn della matrice piena. Il **fattore di compressione** è $\rho(k) = k(m+n+1)/mn$. E' esattamente il conto della slide Reduction of memory occupation, qui applicato al payload da nascondere. Implementazione: `svd_core.compression_factor`.

2.4 Legame con la decomposizione spettrale e condizionamento

Le colonne di V e U sono gli autovettori di $A^T A$ e $A A^T$, e $\sigma_i = \sqrt{\lambda_i}$: il modulo `svd_core.verify_svd_eigendecomposition` verifica questa identità a meno della precisione di macchina. Il **numero di condizionamento** $\kappa(A) = \sigma_1/\sigma_r$ misura quanto i piccoli valori singolari amplifichino il rumore: come osservato nelle slide sui sistemi rettangolari, modificare un σ piccolo è fragile. Questo motiva la scelta progettuale di nascondere l'informazione nel valore singolare **massimo** σ_1 , la componente più stabile (Sez. 3.3). La pseudoinversa di Moore-Penrose $A^+ = V \Sigma^+ U^T$ e la sua versione troncata, anch'esse trattate a lezione, sono implementate in `svd_core.pseudoinverse` e verificate nei test.

3. Metodo proposto

La pipeline elabora una coppia (cover, segreto) in cinque passi:

- 1 il segreto viene **compresso** con SVD troncata in fattori compatti;
- 2 YOLO produce una **mappa di priorità** dal contenuto del cover;
- 3 il payload viene **nascondito** nei blocchi del cover modulando σ_1 (QIM), riempiendo prima lo sfondo;
- 4 il segreto viene **estratto in modo cieco** e ricostruito via SVD inversa;
- 5 YOLO viene riapplicato a cover e stego per misurare la **preservazione semantica**.

3.1 Compressione del segreto (SVD troncata)

L'immagine segreta S (grayscale) è sostituita dalla sua approssimazione di rango k e serializzata in un payload auto-descrittivo: un'intestazione di 9 byte (magic, versione, altezza, larghezza, k) seguita dai fattori σ_k (float16), U_k e V_k^T (quantizzati a int8). La quantizzazione dei fattori riduce ulteriormente il payload. Il decoder legge prima l'intestazione e poi esattamente il numero di bit atteso. Implementazione: `steganography.compress_secret / decompress_secret`.

3.2 Embedding nel dominio SVD a blocchi (QIM su σ_1)

Il cover è diviso in blocchi $B \times B$. Per ogni blocco portante $A = U\Sigma V^T$ si codifica un bit nel valore singolare massimo σ_1 tramite **Quantisation Index Modulation** con passo Δ :

$$\sigma_1' = \lfloor \sigma_1 / \Delta \rfloor \cdot \Delta + (0.25 \text{ o } 0.75) \cdot \Delta \text{ a seconda del bit}$$

Il blocco viene ricostruito come $A' = U\Sigma'V^T$ e la decodifica è **cieca**: il bit si legge dalla parte frazionaria di σ_1/Δ (soglia 0.5), con margine di robustezza $\Delta/4$. Si codifica in σ_1 per due ragioni complementari, entrambe radicate nella SVD: (a) σ_1 concentra quasi tutta l'energia del blocco (Eckart-Young), quindi è la componente più stabile sotto perturbazioni; (b) la distorsione introdotta è $\|\delta \cdot u_1 v_1^T\|_F = |\delta|$, **distribuita su tutti i pixel del blocco** perché u_1, v_1 hanno norma unitaria — quindi impercettibile pixel per pixel.

3.3 Guida YOLO (occultamento adattivo al contenuto)

YOLOv8 rileva gli oggetti nel cover; dalle bounding box si costruisce una mappa di saliency che assegna priorità alta agli oggetti e bassa allo sfondo. L'ordine di riempimento dei blocchi è deciso da questa mappa (sfondo prima, oggetti per ultimi), con una permutazione pseudo-casuale basata su chiave a rompere i pareggi. Lo stesso ordinamento è ricostruibile in fase di estrazione. In assenza di rilevatore lo schema ripiega su una permutazione cieca basata solo sulla chiave, senza bisogno del detector. Implementazione: `yolo_guidance.priority_map`, `steganography.embedding_order`.

3.4 Robustezza: codice a ripetizione

Per la robustezza ogni bit logico viene scritto in R siti consecutivi (codice a ripetizione) e decodificato a **voto di maggioranza**. Questo aumenta la resistenza agli errori al prezzo di una capacità ridotta di un fattore R .

4. Implementazione e punti operativi

Il progetto è in Python (NumPy, OpenCV, scikit-image, Ultralytics YOLOv8, Matplotlib). I moduli principali sono: `svd_core` (matematica SVD), `steganography` (codec del segreto + embedding/estrazione), `yolo_guidance` (rilevamento e metriche), `metrics`, `attacks`, `dataset` e `pipeline` (orchestrazione).

Per illustrare il compromesso capacità↔robustezza sono definiti due **punti operativi** di riferimento, usati in tutti gli esperimenti:

Parametro	High-Capacity (HC)	Robust (RB)
Lato blocco SVD B	8×8	16×16
Passo QIM Δ	24.0	128.0
Ripetizione R	1	3
Segreto	64×64 , $k=10$	16×16 , $k=3$
Payload (bit)	10472	888
Capacità' (bpp)	0.0469	0.0039
Obiettivo	max capacità + impercettibilità	resistenza agli attacchi

Le tre leve sono tutte di natura SVD: blocchi più grandi (B) concentrano più energia in σ_1 (più robusto, meno capacità); un passo Δ maggiore allarga il margine $\Delta/4$ (più robusto, più distorsione); la ripetizione R aggiunge ridondanza di canale a scapito della capacità.

5. Protocollo sperimentale

- **Dataset:** COCO-128, 128 immagini reali di COCO, cover ridimensionati a 512×512; in totale 630 oggetti rilevati da YOLO, con detection presenti nel 97.7% delle immagini.
- **Segreto:** logo grayscale 64×64 (HC) / 16×16 (RB), compresso via SVD troncata.
- **Fedelta':** PSNR, SSIM, MSE tra cover e stego, sia globali sia per regione (oggetto vs sfondo).
- **Payload:** correlazione normalizzata (NC) e PSNR del segreto recuperato, bit error rate (BER).
- **Downstream:** detection preservation rate, IoU medio, mAP@0.5 e |Δconfidenza| tra le rilevazioni su cover e su stego.
- **Attacchi:** JPEG (q90/q75/q50), rumore gaussiano, blur 3×3, filtro mediano 3×3, sale e pepe, ridimensionamento al 50%.
- **Costo:** l'intera batteria su 128 immagini (HC+RB, baseline, attacchi, downstream) gira in ~10.8 minuti su CPU.

6. Risultati

6.1 Compressione del segreto via SVD troncata

La Tab. 2 e la Fig. 3 quantificano il compromesso qualità↔payload della compressione del segreto al variare del rango k (segreto 64×64). Già' con $k=10$ si trattiene il 99.1% dell'energia con un payload di soli 1309 byte (fattore di compressione 0.31); aumentando k la fedeltà cresce ma il payload anche, fino a superare la matrice piena. La Fig. 4 mostra visivamente come la ricostruzione migliori con k .

k	Payload (byte)	Compressione $\rho(k)$	Energia trattenuta	PSNR ricostr. (dB)
2	269	0.063	0.9515	16.74
4	529	0.126	0.9737	19.42
6	789	0.189	0.9820	21.00
8	1049	0.252	0.9874	22.52
10	1309	0.315	0.9911	23.97
12	1569	0.378	0.9936	25.31
16	2089	0.504	0.9969	28.10
20	2609	0.630	0.9986	30.75
24	3129	0.756	0.9993	32.67
32	4169	1.008	0.9999	35.90

Tab. 2 — Qualità di ricostruzione, payload ed energia della SVD troncata del segreto al variare di k (da `results/secret_compression.csv`).




Fig. 3 — PSNR ed energia trattenuta (sinistra) e fattore di compressione (destra) del segreto al variare del rango k .




Fig. 4 — Ricostruzione del segreto al crescere di k : la correlazione normalizzata (NC) con l'originale aumenta con il rango.

6.2 Impercettibilità

In modalità HC cover e stego sono praticamente indistinguibili: PSNR medio **47.39 dB** (deviazione standard appena 0.13 dB su 128 immagini) e SSIM **0.9950**. La modalità RB, più robusta, paga in qualità (PSNR **39.04 dB**, SSIM **0.9820**) a causa del passo Δ molto maggiore. La Fig. 5 mostra le distribuzioni: estremamente concentrate, segno di un comportamento stabile su tutto il dataset.




Fig. 5 — Distribuzione di PSNR (sinistra) e SSIM (destra) cover→stego per le due modalità.

6.3 Protezione degli oggetti tramite YOLO

La guida YOLO sposta il payload nello sfondo: il PSNR **nelle regioni degli oggetti** sale da 47.40 dB (baseline senza guida) a **50.40 dB** con la guida, mentre lo sfondo scende simmetricamente da 47.40 a 46.82 dB. Il miglioramento sugli oggetti è positivo nel **96.8% delle immagini** (guadagno mediano +1.47 dB; in molte immagini la regione degli oggetti resta del tutto intatta, con PSNR che tende all'infinito). E' esattamente il comportamento desiderato: spostare il rumore di embedding là dove conta meno. La Fig. 7 lo mostra qualitativamente — la mappa $|\text{cover}-\text{stego}|$ evita nettamente le regioni degli oggetti, che coincidono con le zone a saliency alta.




Fig. 6 — PSNR per regione (oggetto vs sfondo): la guida YOLO protegge gli oggetti. A destra la distribuzione del PSNR sugli oggetti.




Fig. 7 — Esempi qualitativi: cover, stego, differenza amplificata [cover-stego], saliency YOLO e segreto recuperato. Le modifiche evitano gli oggetti.

6.4 Preservazione del contenuto semantico (downstream)

Le rilevazioni di YOLO si conservano quasi perfettamente dopo l'embedding: detection preservation rate medio **0.961**, mAP@0.5 medio **0.959**, IoU medio **0.986** e variazione media di confidenza appena **0.016**. Le rilevazioni restano perfettamente invariate nell'**79.2% delle immagini**. Da notare che la guida YOLO migliora anche questo aspetto rispetto alla baseline (preservation 0.961 vs 0.942). Lo stego è quindi utilizzabile in una pipeline di AI a valle senza degradarne le prestazioni — una proprietà non ovvia e di interesse pratico.




Fig. 8 — Distribuzione di detection preservation rate, mAP@0.5 (stego vs cover) e $|\Delta \text{confidenza}|$ sulle 128 immagini.

6.5 Recupero del segreto in assenza di attacchi

Su immagine non attaccata il segreto si recupera con NC medio **0.923** (mediana 0.977; $\text{NC} \geq 0.95$ nell'83.6% delle immagini) e BER medio **0.00150**, con il 57.8% delle immagini a BER nullo. In modalità RB il payload è ancora più affidabile (BER nullo nell'86.7% delle immagini). Il limite di fedeltà in pulito non è dovuto all'estrazione (che è quasi perfetta) ma alla **compressione SVD** del segreto: è il prezzo del basso rango scelto per contenere il payload, come già visto in Sez. 6.1.

6.6 Robustezza agli attacchi

La Tab. 3 e la Fig. 9 riassumono la robustezza. La modalità RB (blocchi 16×16 , Δ grande, ripetizione $\times 3$) resiste bene agli attacchi comuni — ad esempio JPEG-q90 con NC 0.91 e BER 0.001, rumore gaussiano con NC 0.86 — mentre la modalità HC, priva di ridondanza e con blocchi piccoli, crolla già al primo attacco: è il prezzo della massima capacità. L'attacco più severo per entrambe è il sale e pepe, che introduce outlier impulsivi che perturbano fortemente σ_1 .

Attacco	NC (HC)	NC (RB)	BER (HC)	BER (RB)
jpeg_q90	0.000	0.908	0.215	0.001
jpeg_q75	0.000	0.859	0.396	0.002
jpeg_q50	0.000	0.480	0.478	0.009
gauss_noise5	0.000	0.863	0.368	0.003
blur_3x3	0.039	0.705	0.193	0.016
median_3x3	0.053	0.515	0.204	0.049
saltpepper_1	0.000	0.054	0.233	0.089
rescale_50	0.014	0.553	0.237	0.036

Tab. 3 — Correlazione normalizzata del segreto recuperato e BER del payload sotto attacco, per le due modalità.




Fig. 9 — NC del segreto recuperato (sinistra) e BER del payload (destra) sotto ciascun attacco.

6.7 Il compromesso capacità↔robustezza

La Fig. 10 colloca le due modalità su un piano capacità (bpp) vs robustezza media (NC sotto attacco). I due punti sono agli estremi opposti di un fronte di Pareto: HC massimizza la capacità (0.0469 bpp) ma è fragile, RB è robusta (NC medio 0.61) ma con capacità $\sim 12\times$ inferiore (0.0039 bpp). Non esiste un punto che massimizzi simultaneamente capacità, impercettibilità e robustezza: la scelta dipende dall'applicazione.




Fig. 10 — Fronte di Pareto capacità↔robustezza tra le due modalità operative.

7. Discussione

- **σ_1 è un dominio di embedding eccellente.** Concentra l'energia del blocco (Eckart-Young) ed è poco sensibile alle perturbazioni, coerentemente con l'osservazione del corso che i piccoli valori singolari amplificano il rumore. La distorsione si distribuisce sull'intero blocco, rendendola impercettibile per pixel.
- **La guida YOLO funziona e non costa capacità.** Migliora la qualità nelle regioni salienti e, soprattutto, mantiene quasi inalterate le rilevazioni a valle, rendendo lo stego utilizzabile in una pipeline di AI.
- **Il compromesso è intrinseco e quantificabile.** Le tre leve (B, Δ , R) sono tutte SVD-based: spostano il sistema lungo il fronte capacità↔robustezza ma non lo superano.

- **Compressione e robustezza sono in tensione.** La SVD troncata massimizza la capacità eliminando la ridondanza spaziale del segreto, ma proprio questo rende il recupero sensibile agli errori di bit: per la robustezza serve reintrodurre ridondanza a livello di canale (ripetizione).

8. Limiti e sviluppi futuri

- L'estrazione guidata richiede la stessa mappa di priorità all'estrazione; una variante completamente cieca usa la permutazione a chiave, rinunciando però alla protezione adattiva degli oggetti.
- Il sale e pepe resta l'attacco più critico: un filtraggio di pre-processing o un codice correttore più forte (es. BCH al posto della semplice ripetizione) migliorerebbero la robustezza.
- La SVD a blocchi non è invariante a rotazioni/crop geometrici; domini sincronizzati (es. template di riallineamento) sarebbero un'estensione naturale.
- Il segreto è un logo sintetico: si potrebbe estendere a payload arbitrari (testo, chiavi) mantenendo la stessa pipeline.

9. Conclusioni

Il progetto mostra come la SVD — cuore del corso — fornisca un quadro unificato per la steganografia di immagini: compressione del segreto via troncamento ottimale (Eckart-Young), dominio di embedding robusto (il valore singolare massimo) e analisi del condizionamento a guidare le scelte progettuali. L'integrazione con YOLO rende l'occultamento adattivo al contenuto e, soprattutto, verificabile a valle. La valutazione su 128 immagini reali quantifica un'impercettibilità elevata, una preservazione semantica quasi perfetta e un compromesso capacità↔robustezza chiaro e interpretabile in termini puramente algebrici.

Riferimenti

- 1 G. Eckart, G. Young, The approximation of one matrix by another of lower rank, Psychometrika, 1936.
- 2 G. Golub, C. Van Loan, Matrix Computations, 4th ed., Johns Hopkins University Press, 2013.
- 3 R. Liu, T. Tan, An SVD-based watermarking scheme for protecting rightful ownership, IEEE Trans. Multimedia, 2002.
- 4 B. Chen, G. Wornell, Quantization index modulation, IEEE Trans. Information Theory, 2001.
- 5 G. Jocher et al., Ultralytics YOLOv8, 2023.
- 6 T.-Y. Lin et al., Microsoft COCO: Common Objects in Context, ECCV 2014.
- 7 M. Popolizio, slide del corso Reducing data dimensionality for AI applications, 2025.

Appendice A — Mappatura concetti del corso ↔ codice

Concetto della lezione	Dove nel progetto
$SVD\ A = U\Sigma V^T$	<code>svd_core.svd_decompose</code>

Concetto della lezione	Dove nel progetto
SVD troncata / Eckart-Young	svd_core.truncated_svd; compressione segreto
Fattore di compressione $k(m+n+1)/mn$	svd_core.compression_factor
SVD $\leftrightarrow$ autovalori ($\sigma=\sqrt{\lambda}$)	svd_core.verify_svd_eigendecomposition
Numero di condizionamento $\kappa=\sigma_1/\sigma_r$	svd_core.condition_number
Pseudoinversa / minimi quadrati	svd_core.pseudoinverse, lstsq_via_svd

Appendice B — Sintesi delle metriche principali

Metrica (HC, media)	Valore
PSNR cover→stego	47.39 dB
SSIM cover→stego	0.9950
PSNR oggetti (guidato)	50.40 dB
Capacità	0.0469 bpp (10472 bit)
NC segreto (pulito)	0.923
BER segreto (pulito)	0.00150
Detection preservation rate	0.961
mAP@0.5 (stego vs cover)	0.959
IoU medio	0.986